

I Convex sets

凸优化学习笔记(I)——凸集

凸集

* 凸集(convex sets)

如果在集合 C 中的任意两点满足:

$$\theta x_1 + (1 - \theta)x_2 \in C$$

其中 $0 \leq \theta \leq 1$, 则集合 C 为凸集。

* 重要例子

1) 超平面和半空间(hyperplanes and halfspaces)

超平面定义为 $\{x | a^T x = b\}$, 半空间被定义为 $\{x | a^T x \leq b\}$ 。从直观上看, 超平面在空间中为一块板子, 划分的两边则分别为半空间。图1




Figure 1: Hyperplanes and Halfplanes

2) 球和椭球

球的形式为

$$\{x | \|x - x_c\|_2 \leq r\} = \{x | (x - x_c)^T (x - x_c) \leq r^2\}$$

椭球的形式为

$$\{x | (x - x_c)^T P^{-1} (x - x_c) \leq 1\}$$

其中 P 是对称的正定矩阵。图2




Figure 2: Ellipsoids

3) 范数球和范数锥

范数球为:

$$\{x \mid \|x - x_c\| \leq r\}$$

范数锥为:

$$\{(x, t) \mid \|x\| \leq t\}$$

图3




Figure 3: Norm cones

4) 多面体

$$\{x \mid a_j^T x \leq b_j, j = 1, \dots, m, c_j^T x \leq d_j, j = 1, \dots, p\}$$

图4




Figure 4: Polyhedra

5) 半正定锥

满足如下条件的集合 \mathbf{S}_+^n 是凸集: $\theta_1, \theta_2 \leq 0$ 并且 $A, B \in \mathbf{S}_+^n$, 则 $\theta_1 A + \theta_2 B \in \mathbf{S}_+^n$ 。其中 \mathbf{S}_+^n 是半正定矩阵。图5




Figure 5: Positive semidefinite cone

★ 保凸运算

1) 交集

如果 A 与 B 均为凸集, 则 A 与 B 的交集也为凸集。

2) 仿射函数

仿射函数即线性函数加常数。如果 x 为凸集, 则 $f(x) = Ax + b$ 为凸集。仿射函数的逆函数也保凸。

3) 线性分式以及透视函数

透视函数即 $P(z, t) = z/t$, 这里 z 是 $n-1$ 维向量, t 是最后一维分量。例如 $P(x_1, x_2, x_3) = \{x_1/x_3, x_2/x_3\}$, P 的定义域是正定对称矩阵。从几何上看, 透视函数类似小孔成像, 是从高维到低维的映射。图6




Figure 6: Perspective function

线性分式即 $f(x) = (Ax + b)/(c^T x + d)$ 其定义域为 $\{x | c^T x + d > 0\}$ 。其逆函数也保凸。线性分式可看做在原集合内做拉伸, 故而保凸。图7




Figure 7: Linear-fractional function

★ 广义不等式

广义不等式即定义了拥有多个分量的变量之间的比较:

$$x \geq_k y \iff x - y \in k$$

$$x >_k y \iff x - y \in \text{int}(k)$$

$\text{int}(k)$ 即 k 的内部。注意 k 必须为凸的、闭的、有非空内部且不包含直线。

★ minimum and minimal

Minimum 即能和集合内所有点进行比较, 且最小。Minimal 即在集合内能比较的所有点中最小。图8

左图为 minimum, 右图为 minimal。




Figure 8: Minimum and minimal

★ 分割面与支撑面

分割面即能将两个集合分开的超平面，有严格不严格之分，严格即两个集合没有交点。两个凸集一定存在一个分割面。

支撑面即集合边缘有个点使得 $a^T x \leq a^T x_0$ 成立。其中 x 是集合内的点， $a \neq 0$ 。

2 Convex functions

凸优化学习笔记(2)——凸函数

凸函数

★ 基本性质及例子

满足如下条件的从 n 维映射到 l 维的函数称凸函数：

$$f(\theta x + (1 - \theta)y) \leq \theta f(x) + (1 - \theta)f(y)$$

其中 $0 \leq \theta \leq 1$ 。凸函数的一维导数有如下性质：

$$f(y) \geq f(x) + \nabla f(x)^T (y - x)$$

可以注意到其实等号右边是 f 在 x 上的一阶泰勒展开式。另外，凸函数的二阶导数大于或等于 0。凸函数举例如下：

1) 指数函数 e^{ax}

2) 幂函数 x^a ，其中 x 大于或等于 0，当 a 不属于 $(0, 1)$ 范围内时为凸函数，否则为凹函数

3) 绝对值的幂函数 $|x|^a$ ，其中 $a > 1$

4) 对数函数 $\log x$

5) 负熵 $x \log x$

6) 范数

7) 最大值函数 $\max(x)$

8) 二次-线性分式函数 $f(x, y) = x^2/y$, y 大于 0

9) 指数和的对数 $f(x) = \log(e^{x_1} + e^{x_2} + \dots + e^{x_n})$, 这其实是一个 soft-max

10) 几何平均 $f(x) = (\prod_{i=1}^n x_i)^{1/n}$

11) 行列式的对数 $\log |A|$, 其中 A 矩阵正定

另外还有两个概念。下水平集: 即函数值小于某个阈值对应的定义域。上镜图: 即 $\{(x, t) | t \geq f(x)\}$, 这是一片函数之上的区域。同时, 凸函数满足 Jensen 不等式。

* 保凸运算

1) 非负加权和, 即把多个函数乘上一个非负的权重加起来。

2) 复合仿射

$$g(x) = f(Ax + b)$$

如果 f 是凸的, 则 g 是凸的。如果 f 是凹的, g 也是凹的。即对自变量仿射后保凸。

3) 逐点最大, 即多个函数中相同自变量取其中最大者, 该运算保凸。

4) 复合

设 $f(x) = h(g(x))$, 则有如下情况:

如果 h 是凸函数且非减, g 是凸函数, 则 f 是凸函数。

如果 h 是凸函数且非增, g 是凹函数, 则 f 是凸函数。

如果 h 是凹函数且非减, g 是凹函数, 则 f 是凹函数。

如果 h 是凹函数且非增, g 是凸函数, 则 f 是凹函数。

f 的拓展函数与上相同。

5) 下界

$$g(x) = \inf_{(y \in C)} f(x, y)$$

如果 f 在 (x, y) 中是凸的, 则 g 也是凸的。

6) 透视函数

$$g(x, t) = tf(x/t)$$

其中 t 大于 0。如果 f 是凸的, 则 g 是凸的, 如果 f 是凹的, g 也是凹的。

* 共轭函数

共轭函数表达式是:

$$f^*(y) = \sup_x (y^T x - f(x))$$

其中 sup 是求上界。其含义是, 给定 y 时平面 $y^T x$ 到 $f(x)$ 的最大距离。下图 9 的虚线即平面 $y^T x$, $y^T x$ 到 $f(x)$ 的最大距离出现在 $f(x)$ 斜率为 y 的切线上。任何函数的共轭函数都是凸的, 因为从表达中可以看到 $f^*(y)$ 是 y 的仿射。

共轭函数的求法是令 $xy - f(x)$, 带入 $f(x)$ 的表达式中并对 x 求导, 使求导结果等于 0 (即求 $f(x)$ 与 xy 距离的最值), 把 x 的结果回代进 $f^*(y) = xy - f(x)$ 即可。




Figure 9: conjugate function

★ 拟凸函数

如果一个函数的下水平集(sublevel sets)是凸集，则该函数是拟凸函数。例如：

- 1) 对数函数 $\log x$
- 2) 上取整函数 $\text{ceil}(x) = \inf \{z \in \mathbb{Z} | z \geq x\}$
- 3) 向量的长度
- 4) $f(x_1, x_2) = x_1 x_2$ ，由于该矩阵的Hessian矩阵不是正定，也不是负定，但是其下水平集是凸集。
- 5) 线性分式 $f(x) = (a^T x + b)/(c^T x + d)$

对于一个函数来说，如果满足其非减，或非增，或存在一个占函数小于该点非增，大于该点非减，则该函数为拟凸的。图10




Figure 10: quasiconvex function

★ 对数凸函数

如果函数的值域大于0，并且 $\log f(x)$ 是凸的，则该函数成对数凸函数。对数凹函数同理。例如：

1) 仿射函数

2) 幂函数 $f(x) = x^a$ ，其中 x 大于0且 a 小于等于0。若 a 大于等于0则为对数凹函数

3) 指数函数

4) 高斯分布的累积分布函数

5) Gamma函数

6) 矩阵的行列式

7) 矩阵的行列式除以迹

需要注意，两个对数凸函数相乘依然是对数凸函数，相加却未必。两个对数凸函数的卷积运算是对数凸函数。对数凸函数的积分运算是对数凸函数。

3 Convex optimization problems

凸优化学习笔记(3)——优化问题

凸优化问题

★ 优化问题的基本形成

$$\begin{array}{ll} \text{minimize} & f_0(x) \\ \text{subject to} & f_i(x) \leq b_i, i = 1, \dots, m \\ & h_i(x) = 0, i = 1, \dots, p \end{array}$$

需要注意的是除了显式的约束外，每个函数还有隐式的定义域约束。整个问题的定义域是所有函数的定义域的交集。对于每个这样的问题，其最优解定义为：

$$p^* = \inf\{f_0(x) | f_i(x) \leq 0, i = 1, \dots, m, h_i(x) = 0, i = 1, \dots, p\}$$

局部最优解定义为半径为 R 的定义域范围内的最小值。如果这是个最小问题，则 $f_0(x)$ 称为损失函数，如果是最大问题，则称为效用函数。

★ 凸优化

凸优化问题定义为如下形式：

$$\begin{array}{ll} \text{minimize} & f_0(x) \\ \text{subject to} & f_i(x) \leq 0, i = 1, \dots, m \\ & a^T x = 0, i = 1, \dots, p \end{array}$$

其中, f_0, \dots, f_m 都是凸函数。非正式地说, 对于一个一般的优化问题, 1) 目标函数是凸函数; 2) 不等式约束是凸函数; 3) 等式约束是仿射函数, 则这个问题是凸优化问题。同时, 从以上的定义可以注意到, 凸优化问题的可行域一定是凸集。如果目标函数是拟凸函数, 则这个问题是拟凸问题。

如果点 x 满足如下等式, 则该点是最优解:

$$\nabla f(x)^T (y - x) \geq 0$$

体现在几何上, 即图11




Figure 11: Convex optimization problems

有时间为了简化理论分析, 可以将问题转化为线性的目标函数:

$$\begin{aligned} & \text{minimize} && t \\ & \text{subject to} && f_i(x) \leq 0, i = 1, \dots, m \\ & && a^T x = 0, i = 1, \dots, p \\ & && f_0(x) - t \leq 0 \end{aligned}$$

同时, 可以通过如下方式求解拟凸问题:

$$f_0(x) \leq t \iff \phi_t(x) \leq 0$$

$$\begin{aligned} & \text{find} && x \\ & \text{subject to} && f_i(x) \leq 0, i = 1, \dots, m \\ & && a^T x = 0, i = 1, \dots, p \\ & && \phi_t(x) \leq 0 \end{aligned}$$

该方法通过在可行域上不停二分查找, 找到一个恰好有可行域的 t , 并求解的 x 即为次优解。

★ 线性规划问题(LP)

问题可描述为:

如下问题可以转换为线性规划, 图12:

$$\begin{array}{ll}\text{minimize} & c^T x + d \\ \text{subject to} & Gx \leq h \\ & Ax = b\end{array}$$

- 1) 营养搭配问题，即每个食物有其价格和营养含量，目标是组合这些食物，在花费最少的情況下满足每一种营养需求。
- 2) 多边形的切比雪夫中心，即寻找多边形内半径最大圆的中心点。
- 3) 多个仿射函数最大值。
- 4) 分片线性极小化。




Figure 12: Linear program

★ 二次规划(QP)

$$\begin{array}{ll}\text{minimize} & (1/2)x^T Px + q^T x + r \\ \text{subject to} & Gx \leq h \\ & Ax = b\end{array}$$

其中 P 为正定矩阵。如果其不等式约束为二次约束，则该问题为二次约束的二次规划(QCQP):

$$\begin{array}{ll}\text{minimize} & (1/2)x^T Px + q^T x + r \\ \text{subject to} & (1/2)x^T P_i x + q_i^T x + r_i, i = 1, \dots, m \\ & Ax = b\end{array}$$

二次规划有如下问题:

- 1) 最小二乘及回归
- 2) 求两个平面之间的距离
- 3) 求方差下界

4) x 带随机损失的线性规划, 即把随机损失的平方作为最小化项加入目标函数中

二阶锥规划(QCQP):

$$\begin{aligned} & \text{minimize} && f^T x \\ & \text{subject to} && \|A_i x + b\|_2 \leq c_i^T x + d \\ & && Fx = g \end{aligned}$$

该规划可用于常数未知的线性规划, 解法1是设置协方差矩阵 P 表示参数随机的程序, 然后把约束条件设为容忍其极大损失; 解法2是设置方差服从正态分布, 通过0.95或者0.99等置信度确定约束范围。图13




Figure 13: Quadratic program

★ 几何规划

单项式函数定义为:

$$f(x) = cx_1^{a_1} x_2^{a_2} \dots x_n^{a_n}$$

多项式函数则定义为多个单项式函数的和:

$$f(x) = \sum_{k=1}^K c_k x_1^{a_{1k}} x_2^{a_{2k}} \dots x_n^{a_{nk}}$$

其中 x 为正。定义几何规划为:

$$\begin{aligned} & \text{minimize} && f_0(x) \\ & \text{subject to} && f_i(x) \leq 1, i = 1, \dots, m \\ & && h_i(x) = 1, i = 1, \dots, p \end{aligned}$$

其中, f_i 为多项函数, h_i 为单项式函数。几何规划不是凸函数, 但可以转换成凸函数, 首先令 $y_i = \log x_i$, 然后在 f_i 外套 \log 函数, 则该问题的指数均转换为仿射函数。

* 广义不等式约束

把约束扩展到广义不等式上，即认为 f_i 的映射结果是一个向量，因此 f_i 所在的不等式是一个广义不等式。这里记录一个半定规划：

$$\begin{array}{ll}\text{minimize} & c^T x \\ \text{subject to} & x_1 F_1 + x_2 F_2 + \cdots + x_n F_n \leq G \\ & Ax = b\end{array}$$

可以看出，该问题包含SOCP，而SOCP包含QCQP，QCQP包含LP。

