Deep Reinforcement Learning 深度增强学习资源(持续更新)

Deep Reinforcement Learning 深度增强学习资源(持续更新)

DQN从入门到放弃1 DQN与增强学习

DQN 从入门到放弃1 DQN与增强学习

⋆ 前言

深度增强学习Deep Reinforcement Learning是将深度学习与增强学习结合起来从而实现从Perception感知到Action动作的端对端学习End-to-End Learning的一种全新的算法。

⋆ 预备条件

概率论、线性代数、Python编程基础

- 深度学习(Deep Learning)
- 增强学习(Reinforcement Learning)

⋆ 增强学习是什么

DEF: 智能体Agent

表示一个具备行为能力的物体，比如机器人，无人车，人等等。

增强学习考虑的问题就是**智能体Agent**和**环境Environment**之间交互的任务。

DEF: 反馈值Reward

所谓的Reward就是Agent执行了动作与环境进行交互后，环境会发生变化，变化的好与坏就用Reward来表示。

DEF: 观察Observation

Observation表示Agent获取的感知信息。

增强学习的任务就是找到一个最优的策略Policy从而使Reward最多。

DQN 从入门到放弃2 增强学习与MDP

DQN 从入门到放弃2 增强学习与MDP

⋆ 增强学习的世界观

- 世界的时间是可以分割成一个一个时间片的，并且有完全的先后顺序，因此可以形成

$$s_0, a_0, r_0, s_1, a_1, r_1, \ldots, s_t, a_t, r_t$$

这样的状态，动作和反馈系列。

- 增强学习中每一次参数的调整都会对世界造成确定性的影响。

⋆ MDP(Markov Decision Process)马尔科夫决策过程

DEF: Markov

一个状态S_t是Markov当且仅当

$$P(s_{t+1}|s_t) = P(s_{t+1}|s_t, s_{t-1}, \ldots, s_1, s_0)$$

P为概率。

一个基本的MDP可以用(S, A, P)来表示，S表示状态，A 表示动作，P表示状态转移概率，也就是根据当前的状态s_t 和a_t转移到s_{t+1}的概率。如果我们知道了转移概率P，也就是称为我们获得了**模型Model**，有了模型，未来就可以求解，那么获取最优的动作也就有可能，这种通过模型来获取最优动作的方法也就称为Model-based 的方法。但是现实情况下，很多问题是很难得到准确的模型的，因此就有Model-free的方法来寻找最优的动作。

⋆ 回报Result

DEF: 回报Result

回报Return来表示某个时刻t的状态将具备的回报：

$$G_t = R_{t+1} + \lambda R_{t+2} + \cdots = \sum_{k=0}^{\infty} \lambda^k R_{t+k+1}$$

上面R是Reward反馈，λ是discount factor折扣因子，一般小于1，就是说一般当下的反馈是比较重要的，时间越久，影响越小。

用价值函数value function $v(s)$来表示一个状态未来的潜在价值。

DEF: value function

value function就是回报的期望：

$$v(s) = \mathbb{E}[G_t|S_t = s]$$

DQN 从入门到放弃3 价值函数与Bellman方程

DQN 从入门到放弃3 价值函数与Bellman方程

⋆ Value Function 价值函数

⋆ 再谈增强学习的意义

L深度学习给了计算机“神经网络大脑”，RL给了计算机学习机制。

★ Bellman方程

$$\begin{aligned} v(x) &= \mathbb{E}[G_t|S_t = s] \\ &= \mathbb{E}[R_{t+1} + \lambda R_{t+2} + \lambda^2 R_{t+3} + \ldots|S_t = s] \\ &= \mathbb{E}[R_{t+1} + \lambda(R_{t+2} + \lambda R_{t+3} + \ldots)|S_t = s] \\ &= \mathbb{E}[R_{t+1} + \lambda G_{t+1}|S_t = s] \\ &= \mathbb{E}[R_{t+1} + \lambda v(S_{t+1})|S_t = s] \end{aligned}$$

DEF: Bellman方程

$$v(s) = \mathbb{E}[R_{t+1} + \lambda v(S_{t+1})|S_t = s]$$

DQN 从入门到放弃4 动态规划与Q-Learning

DQN 从入门到放弃4 动态规划与Q-Learning

★ 上文回顾

Bellman方程透出的含义就是价值函数的计算可以通过迭代的方式来实现。

★ Action-Value function 动作价值函数

DEF: 动作价值函数Action-Value function

$$\begin{aligned} Q^\pi(s,a) &= \mathbb{E}[r_{t+1} + \lambda r_{t+2} + \lambda^2 r_{t+3} + \ldots|s,a] \\ &= \mathbb{E}_{s'}[r + \lambda Q^\pi(s',a')|s,a] \end{aligned}$$

★ Optimal value function 最优价值函数

最优动作价值函数和一般的动作价值函数的关系：

$$Q^*(s,a) = \max_\pi Q^\pi(s,a)$$

$$Q^*(s,a) = \mathbb{E}_{s'}[r + \lambda \max_{a'} Q^*(s',a')|s,a]$$

★ 策略迭代Policy Iteration

Policy Iteration的目的是通过迭代计算value function 价值函数的方式来使policy收敛到最优。

Policy Iteration本质上就是直接使用Bellman方程而得到的：

$$\begin{aligned} v_{k+1}(s) &\doteq \mathbb{E}_\pi[R_{t+1} + \gamma v_k(S_{t+1})|S_t = s] \\ &= \sum_a \pi(a|s) \sum_{s',r} p(s',r|s,a)[r + \gamma v_k(s')] \end{aligned}$$

Policy Iteration一般分成两步：

1. Policy Evaluation 策略评估。目的是更新Value Function，或者说更好的估计基于当前策略的价值。

2. Policy Improvement 策略改进。使用Greedy policy 产生新的样本用于第一步的策略评估。

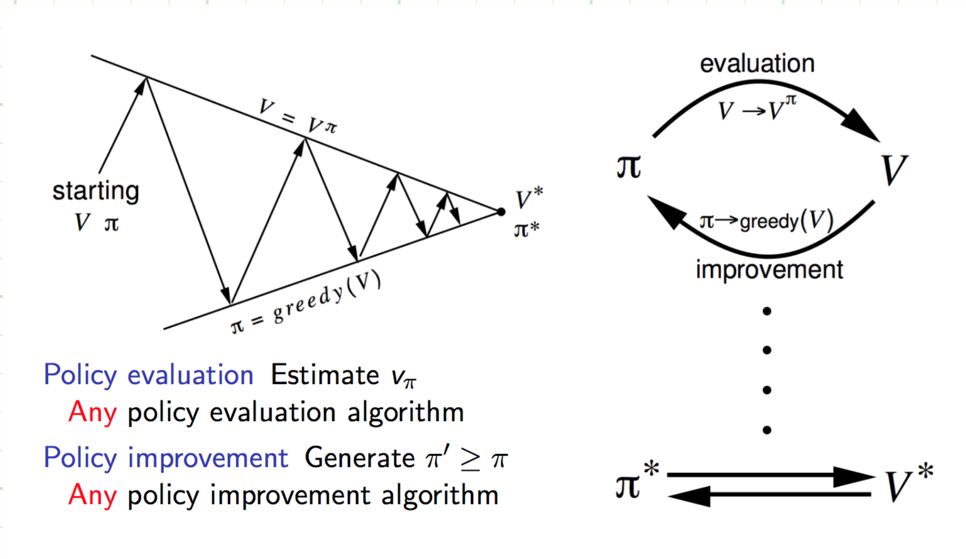

1. Initialization

   $V(s) \in \mathbb{R}$ and $\pi(s) \in \mathcal{A}(s)$ arbitrarily for all $s \in \mathcal{S}$

2. Policy Evaluation

   Repeat

   $\Delta \leftarrow 0$

   For each $s \in \mathcal{S}$

   $v \leftarrow V(s)$

   $V(s) \leftarrow \sum_{s',r} p(s', r|s, \pi(s))[r + \gamma V(s')]$

   $\Delta \leftarrow \max(\Delta, |v - V(s)|)$

   Until $\Delta < \theta$ (a small positive number)

3. Policy Improvement

   $policy - stable \leftarrow true$

   For each $s \in \mathcal{S}$

   $a \leftarrow \pi(s)$

   $\pi(s) \leftarrow argmax_a \sum_{s',r} p(s', r|s, a)[r + \lambda V(s')]$

   if $a \neq \pi(s)$, then $policy - stable \leftarrow false$

   if $policy - stable$, then stop and return V and π; else go to 2

Figure 1: Policy iteration算法

这里policy evaluation部分的迭代需要知道state状态转移概率p，也就是说依赖于model模型。

⋆ Value Iteration 价值迭代

Value Iteration则是使用Bellman 最优方程得到

$$
\begin{aligned}
v_* &= \max_a \mathbb{E}[R_{t+1} + \gamma v_*(S_{t+1}) | S_t = s, A_t = a] \\
&= \max_a \sum_{s', r} p(s', r | s, a)[r + \gamma v_*(s')]
\end{aligned}
$$

然后改变成迭代形式

$$
\begin{aligned}
v_{k+1}(s) &\doteq \max_a \mathbb{E}[R_{t+1} + \gamma v_k(S_{t+1}) | S_t = s, A_t = a] \\
&= \max_a \sum_{s', r} p(s', r | s, a)[r + \gamma v_k(s')]
\end{aligned}
$$

value iteration的算法如下：

Initialize array V arbitrarily (e.g., $V(s) = 0$ for all $s \in \mathcal{S}^+$)

Repeat

  $\Delta \leftarrow 0$

  For each $s \in \mathcal{S}$

    $v \leftarrow V(s)$

    $V(s) \leftarrow \max_a \sum_{s', r} p(s', r | s, a)[r + \gamma V(s')]$

    $\Delta \leftarrow \max(\Delta, |v - V(s)|)$

until $\Delta < \theta$ (a small positive number)

Output a deterministic policy, π, such that

  $\pi(s) = argmax_a \sum_{s', r} p(s', r | s, a)[r_\gamma V(s')]$

Figure 2: Value iteration算法

value iteration较之policy iteration更直接，不过问题也都是一样，需要知道状态转移函数p才能计算。

⋆ Q-Learning

Q Learning提出了一种更新Q值的办法：

$$
Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha(R_{t+1} + \lambda \max_a Q(S_{t+1}, a) - Q(S_t, A_t))
$$

具体的算法如下：

初始化$Q(s, a)$，$\forall s \in S$，$a \in A(s)$，任意的数值，并且$Q(terminal-state, \cdot) = 0$

重复(对每一节episode)

　初始化状态S

　重复(对episode中的每一步)

　　使用某一个policy比如($\epsilon - greedy$)根据状态S选取一个动作执行

　　执行完动作后，观察reward和新的状态S'

　　$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha(R_{t+1} + \lambda \max_a Q(S_{t+1}, a) - Q(S_t, A_t))$

　　$S \leftarrow S'$

　循环直到S终止

Figure 3: Q-Learning算法

★ Exploration and Exploitation 探索与利用

- 以Q-Learning算法叫做Off-policy的算法。
- Q-Learning完全不考虑model模型也就是环境的具体情况，只考虑看到的环境及reward，因此是model-free的方法。

选择怎样的policy来生成action呢？有两种做法：

- 随机的生成一个动作。
- Greedy policy贪婪策略，如ϵ-Greedy策略。

DQN从入门到放弃5 深度解读DQN算法

DQN从入门到放弃5 深度解读DQN算法